



《RAG技术应用》

《 从知识库搭建到RAG实践》



黑马程序员
www.itheima.com

传智教育旗下
高端IT教育品牌



目录

Contents

- 什么是RAG
- RAG中的知识库如何构建
- 案例实践：英雄联盟游戏助手

场景引入：Bot遇到的难题




用户提问

"帮我介绍行下 LOL 中《流光镜影》这个英雄的技能有哪些



普通大模型回答

"在《英雄联盟》（League of Legends, LOL）当前版本（截至2025年12月）中，并没有名为《流光镜影》的英雄。"



✗ 问题所在


- ◆ 知识过时，无法回答
- ◆ 用户体验差
- ◆ Bot价值大打折扣



解决方案：RAG (Retrieval-Augmented Generation) 检索增强技术

I 什么是RAG

RAG是一种结合知识检索和语言生成的人工智能技术,主要用于解决大型语言模型幻觉问题



基本原理：在生成回答时,先从知识库中检索相关文档，将检索到的文档与原始问题一起输入LLM，LLM基于检索内容生成最终答案。

总结

1. 传统LLM的缺陷？

答案：消息滞后（无法获取最新的知识）

2. RAG的原理是什么？

答案：先将问题基于知识库检索问题相关的上下文，然后在将问题和上下文结合送入大模型回答

3. RAG解决什么问题？

答案：大模型幻觉问题



目录

Contents

- 什么是RAG
- RAG中知识库如何构建
- 案例实践：英雄联盟游戏助手

知识库构建：文档准备



文档类型

支持格式

PDF、Word、TXT

适用场景

攻略文章、教程文档

LOL案例

英雄攻略PDF



表格类型

支持格式

Excel、CSV

适用场景

结构化数据、统计信息

LOL案例

英雄属性表

文档预处理建议：

- 清理无关内容（广告、水印）
- 按主题分类整理
- 文件命名规范（含关键信息）

■ 知识库构建：文档切片

文档切片：为了适应大语言模型的上下文长度限制，并提升检索的精确度和效率。

切分方式：

①按字符数切分

固定长度（如每300字一段）

②按符号切分

按照句号、换行符、感叹号等

③按语义切分

识别主题变化点智能切分

一般选择方式：

✎ 按照符号和字符长度一块切分：一般200-500字/段

长度太小，上下文不完整，检索不准，长度太大，无关信息过多，干扰判断

■ 知识库构建：文档向量化



文档向量化：将切分后的文本进行向量数字化，便于计算问题和文档的相似性。

💡 什么是向量化？

“问题：盲僧Q技能” → [0.8, 0.6, ...]

文档1：“烹饪技巧” → [0.1, 0.8, ...]

文档2：“盲僧出装” → [0.7, 0.5, ...]



向量化作用：语义理解；相似度计算；快速检索

总结

1. RAG知识库构建的主要流程？

答案：文档准备--》文档切分--》文档向量化

2. 文档为什么要切片？

答案：为了适应大语言模型的上下文长度限制，并提升检索的精确度和效率

3. 文档向量化原因？

答案：文本进行向量数字化，便于计算问题和文档的相似性。



目录

Contents

- 什么是RAG
- RAG中知识库如何构建
- 案例实践：英雄联盟游戏助手

环节1：创建LOL攻略知识库

基本操作步骤：

Step 1: 创建知识库

进入Dify选择知识库创建

Step 4: 构建索引

将分段后的文档进行向量化

Step 2: 选择数据源

上传文本原始文件

Step 5: 检索设置

向量检索/全文检索/混合检索

Step 3: 文本分段

选择(设置)分段方式

Step 6: 查看结果

预览文本处理的效果

环节2：让 Agent 应用知识库

操作步骤：

Step 1：创建空白应用

构建Agent智能体

Step 2：构建提示词

明确角色 → 说明功能 → 规范回复格式

Step 3：选择知识库

编排模块→ 知识库→点击“添加知识库”

Step 4：结果验证

调试→ 输入问题→验证结果



关键提示：

一个Agent可以关联多个知识库 设置优先级可控制检索顺序

总结

1. 实现LOL游戏助手的过程？

1. 上传文件
2. 文档切分
3. 文档向量化
4. 存储知识库
5. 问题检索知识库
6. 获取相关上下文
7. 问题和上下文融合
8. 送入LLM
9. 得到预测结果